

Mach - BDA - DataViz

Rapport de projet

**Analyse et prédiction autour de la sévérité et
des facteurs influents des accidents de la route**



Auteurs:

Aymeric Le Riboter, Axelle Destombes, Erwann Lesech, Evan Pennec

June 25, 2026

Sommaire

1	Introduction	1
2	Dataset	2
3	EDA : Analyse Exploratoire des données	4
3.1	Distribution de la Sévérité	4
3.2	Analyse Temporelle	4
3.3	Conditions Météorologiques et Direction du Vent	6
3.4	Infrastructures Routières	8
4	Formalisation des problèmes de machine learning	8
	Classification	8
	Regression	8
	Clustering	9
	Détection d'anomalies	9
5	Prétraitement du dataset	9
5.1	Nettoyage des colonnes	9
5.2	Gestion des valeurs manquantes	9
5.3	Estimation automatique des phases de la journée	10
5.4	Transformation des données catégorielles	10
5.5	Création de jeux de données spécialisés	10
6	Méthodes de résolutions et résultats	11
6.1	Classification de la sévérité	11
6.2	Régression sur la durée impactée sur le trafic de l'accident	12
6.3	Clustering sur les positions des accidents et leurs champs associés	13
6.4	Détection d'anomalies parmi les séries d'accidents	15
7	Discussion des résultats et limites	17
8	Conclusion	18

1 Introduction

La sécurité routière est un enjeu majeur de société, autant sur le plan humain que sur le plan économique. Chaque année, les accidents de la route causent des milliers de victimes, et leur analyse constitue un levier essentiel pour anticiper les risques et orienter les politiques de prévention.

À travers ce projet, nous cherchons à tirer de la valeur ajoutée d'un jeu de données d'enregistrements d'accidents survenus aux États-Unis en utilisant de manière rigoureuse et complète les informations qu'il contient.

L'objectif initial est de mener une exploration approfondie du dataset, notamment grâce à la visualisation, afin de faire émerger des pistes d'interprétations, des corrélations significatives, voire des anomalies. Ces premiers résultats orientent ensuite la formalisation de problèmes concrets pouvant être adressés par des techniques de machine learning.

L'objectif est double : comprendre les facteurs sous-jacents aux accidents par des analyses exploratoires et développer des modèles prédictifs permettant, par exemple, d'estimer la sévérité d'un accident en fonction de ses caractéristiques.

Le rapport est structuré de la manière suivante : nous présentons d'abord le dataset utilisé, avant de détailler la phase d'analyse exploratoire des données. Nous formalisons ensuite les problèmes rencontrés sous forme d'approches machine learning, et expliquons les méthodes retenues pour les résoudre. Enfin, nous discutons les résultats obtenus avant de conclure sur les apports et les limites de notre démarche.

2 Dataset

Le dataset utilisé dans ce projet est intitulé *“US Accidents (2016–2023): A Country-wide Traffic Accident Dataset”*¹ [1]. Il regroupe des données sur des accidents de la route survenus aux États-Unis entre février 2016 et mars 2023, couvrant l’ensemble du territoire américain.

Les données ont été collectées en temps réel à partir de plusieurs APIs spécialisées dans le trafic routier. Ces APIs agrègent des informations issues de différentes sources : départements des transports, forces de l’ordre, caméras de surveillance routière, et capteurs présents sur les infrastructures. Le dataset contient environ 7,7 millions d’enregistrements d’accidents.

Présentation des variables du dataset

Le dataset contient un ensemble riche de variables décrivant chaque accident sous différents aspects. Le tableau suivant regroupe ces variables par thématique afin d’en faciliter la lecture et l’interprétation :

Catégorie	Variables et description
Identifiant et source	ID : identifiant unique de l’accident. Source : source d’origine de la donnée (API ou service de trafic).
Informations temporelles	Start_Time, End_Time : date/heure de début et de fin de l’accident. Weather_Timestamp : date/heure de la mesure météo associée. Sunrise_Sunset, Civil_Twilight, Nautical_Twilight, Astronomical_Twilight : périodes de la journée (jour/nuit).
Localisation	Start_Lat, Start_Lng, End_Lat, End_Lng : coordonnées GPS. Street, City, County, State, Zipcode, Country, Timezone : informations d’adresse. Airport_Code : station météo la plus proche.
Gravité et impact	Severity : niveau de sévérité de l’accident, de 1 (léger) à 4 (grave), basé sur l’impact sur la circulation. Distance(mi) : distance affectée par l’accident (en miles). Description : description textuelle de l’événement.
Conditions météorologiques	Temperature(F), Wind_Chill(F), Humidity(%), Pressure(in), Visibility(mi), Wind_Speed(mph), Precipitation(in), Wind_Direction, Weather_Condition : variables météo au moment de l’accident.
Infrastructures et éléments routiers	Amenity, Bump, Crossing, Give_Way, Junction, No_Exit, Railway, Roundabout, Station, Stop, Traffic_Calming, Traffic_Signal, Turning_Loop : présence d’éléments ou d’aménagements spécifiques à proximité du lieu de l’accident.

Table 1: Présentation des variables du dataset US Accidents (2016–2023)

Focus sur la variable de sévérité

La variable *Severity* constitue une composante essentielle de notre analyse. Elle représente une "estimation de la gravité de l’accident", telle qu’évaluée dans le dataset. Cette gravité ne reflète pas directement l’impact sur la circulation, mais plutôt le "niveau de dangerosité ou de conséquences associées à l’accident". Elle est généralement catégorisée de la façon suivante :

- **1** : accident mineur (ex. accrochage sans blessure),

¹<https://www.kaggle.com/datasets/sobhanmoosavi/us-accidents>

- 2 : accident modéré (ex. dommages matériels notables),
- 3 : accident sérieux (ex. possible blessure),
- 4 : accident grave (ex. blessures graves, évacuation, intervention d'urgence).

Cette variable, de type catégorielle ordonnée, se prête particulièrement bien à une tâche de **classification supervisée**. Elle sera donc utilisée comme cible principale dans la modélisation prédictive.

Pour aller plus loin dans l'analyse de l'effet d'un accident sur le trafic, nous intégrerons également les variables temporelles `Start_Time` et `End_Time`, qui permettent de calculer la **durée de l'accident** :

$$\text{Duration (secondes)} = \text{End_Time} - \text{Start_Time}$$

Cette durée pourra être interprétée comme un proxy de l'impact temporel de l'accident sur le trafic routier et utilisée dans des tâches de **régression** ou de **clustering**, afin d'identifier les types d'accidents générant des blocages prolongés ou des ralentissements plus persistants.

D'autres variables comme `Distance(mi)`, les conditions météorologiques, ou les coordonnées géographiques seront également exploitées dans l'étude du comportement spatio-temporel des accidents, comme détaillé dans les sections suivantes.

Dans la section suivante, nous procéderons à une analyse exploratoire afin de mieux comprendre la structure du dataset, la distribution des variables, la présence de valeurs manquantes, ainsi que les premières tendances significatives à en extraire.

3 EDA : Analyse Exploratoire des données

3.1 Distribution de la Sévérité



Figure 1: Distribution des accidents par sévérité

La sévérité 2 domine largement avec un peu plus de 6 millions d'accidents, représentant environ 80 % du total, ce qui montre une forte proportion d'accidents modérés. En comparaison, la sévérité 3 représente environ 1,3 million (17 %), tandis que la sévérité 4 atteint 200 000 cas (2,7 %), et la sévérité 1 reste très rare avec 67 000 accidents (0,9 %). Ce déséquilibre suggère que les données pourraient être biaisées vers les perturbations modérées, peut-être à cause d'une collecte plus orientée vers ce type d'événements.

3.2 Analyse Temporelle




Figure 2: Nombre d'accidents de sévérité 2 par mois

Pour les accidents de sévérité 2, décembre se distingue avec environ 700 000 cas, suivi de novembre avec 650 000, ce qui pourrait être lié aux conditions hivernales comme la neige ou le verglas. Janvier (600 000) et octobre (600 000) suivent de près, tandis que juin marque un creux, probablement en raison d'une saison plus clémente. Cette variabilité saisonnière indique clairement une influence des conditions météorologiques sur la fréquence des accidents.




Figure 3: Nombre d'accidents de sévérité 2 par jour

Pour la sévérité 2, on remarque que les jours de la semaine, du lundi au vendredi, représentent la majorité des accidents, probablement dû au fait qu'il y ait plus de trafic les jours de travail. Au contraire, le week-end, les accidents sont bien moins nombreux, suggérant une réduction du trafic professionnel en fin de semaine.




Figure 4: Nombre d'accidents de sévérité 2 par heure

Les accidents de sévérité 2 culminent entre 6h et 8h ainsi qu'entre 15h et 18h, ce qui correspond aux heures de pointe et montre une corrélation évidente avec la densité de trafic. En revanche, les heures nocturnes, de 0h à 5h, restent faibles, probablement en raison d'une activité routière réduite.

3.3 Conditions Météorologiques et Direction du Vent




Figure 5: Nombre d'accidents par condition météo

Les conditions "Fair" dominent avec 2,56 millions d'accidents, suivies de "Mostly Cloudy" avec 1,02 million, ce qui pourrait s'expliquer par une circulation plus intense par beau temps. Les conditions extrêmes comme "Fog" ou "Light Snow" sont moins fréquentes, mais elles pourraient indiquer des risques accrus dus à une visibilité ré-

duite. Cela montre que le volume de circulation semble jouer un rôle plus important que les intempéries.




Figure 6: Top 15 conditions météo avec sévérité moyenne

Les conditions comme "Light Blowing Snow" (sévérité moyenne de 3,6) et "Patches of Fog/Windy" (3,4) affichent les niveaux de gravité les plus élevés, suggérant que le vent et le brouillard augmentent les dangers. "Heavy Freezing Rain/Windy" (3,0) et "Light Fog" (3,2) confirment cet impact, avec une sévérité supérieure à 3, contre environ 2,6 pour des conditions plus stables, ce qui met en évidence l'effet des intempéries glissantes.




Figure 7: Nombre d'accidents par direction du vent

Les directions "South" et "CALM" dominent, probablement dues aux vents dominants et à un temps stable favorisant la circulation. "West" et "North" suivent, tandis que "NE" est rare, peut-être à cause de variations régionales comme des barrières géographiques. Cela indique que la direction du vent influence la fréquence des accidents selon les conditions locales.

3.4 Infrastructures Routières




Figure 8: Nombre d'accidents par infrastructure

Les infrastructures comme "Traffic Signal" et "Crossing" sont les plus associées aux accidents, ce qui indique des zones urbaines denses avec feux et passages piétons, où les interactions entre véhicules et piétons sont fréquentes. "Junction" montre aussi un risque élevé aux carrefours. En revanche, "Roundabout" et "Turning Loop" sont presque inexistantes, suggérant une efficacité de ces aménagements ou un faible usage. Cette prédominance des infrastructures urbaines pointe vers une corrélation avec la congestion et la densité de population.

4 Formalisation des problèmes de machine learning

Classification de la sévérité

L'objectif de cette tâche va être de prédire la sévérité des accidents. C'est donc une tâche de classification supervisée multiclasse. Un des problèmes qui peut être identifié grâce à l'EDA est que les classes sont très déséquilibrées, la plupart des accidents étant de sévérité 2 ou 3. Ainsi pour évaluer ces modèles, le f1-score sera une très bonne métrique car elle est moins impactée par le déséquilibre entre les classes. En effet elle donne un bon compromis entre précision et recall.

Régression sur la durée impacté sur le trafic de l'accident

Ce problème consiste à prédire la durée d'impact d'un accident à partir de ses caractéristiques contextuelles. Il s'agit d'une tâche de **régression supervisée**, où l'on cherche à approximer une variable continue $y \in \mathbb{R}^+$ représentant la durée, définie comme :

$$y = \text{End_Time} - \text{Start_Time}$$

Le but est donc de trouver une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}^+$ telle que $f(X) \approx y$, où X est un vecteur de caractéristiques descriptives de l'accident (météo, localisation, heure, etc.).

Clustering sur les positions des accidents et leurs champs associés

Cette tâche correspond à un problème de **clustering non supervisé**, visant à regrouper les accidents en clusters homogènes selon leurs caractéristiques spatiales et contextuelles.

Formellement, étant donné un ensemble d'accidents représentés par des vecteurs $X_1, X_2, \dots, X_m \in \mathbb{R}^n$, l'objectif est de partitionner cet ensemble en K groupes $\{C_1, C_2, \dots, C_K\}$ tels que les éléments d'un même cluster soient similaires selon une mesure de distance ou de densité.

Ces regroupements permettent d'identifier des schémas récurrents ou des zones géographiques à risque.

Détection d'anomalies parmi les séries d'accidents

Cette tâche s'inscrit dans le cadre de l'**apprentissage automatique non supervisé**, plus précisément dans la **détection d'anomalies**, visant à identifier des observations inhabituelles ou rares au sein des données historiques d'accidents.

Considérons une série temporelle d'accidents représentée sous forme d'un ensemble de vecteurs $x_1, x_2, \dots, x_T$, où chaque vecteur $x_t \in \mathbb{R}^n$ encode les caractéristiques agrégées ou individuelles d'accidents sur une unité temporelle donnée (par exemple, un jour donné). L'objectif est alors de déterminer les points x_t qui s'écartent significativement du comportement « normal » observé dans le reste de la série.

Cela permet de détecter, par exemple, des jours présentant un nombre anormalement élevé d'accidents, des schémas géographiques atypiques ou des concentrations rares dans le temps – tels que des séries d'accidents dus à des conditions météorologiques exceptionnelles (ex. : le 23 décembre 2019 en Californie lors d'un épisode de gel intense).

5 Prétraitement du dataset

Afin de garantir la qualité des analyses et des modèles développés, une phase de prétraitement a été réalisée sur le dataset brut. Cette étape, implémentée en PySpark pour des raisons de scalabilité, a permis d'assurer la propreté, la cohérence et l'exploitabilité des données. Elle a conduit à la génération de trois jeux de données spécialisés : pour la classification, le clustering, et la détection d'anomalies.

5.1 Nettoyage des colonnes

Certaines colonnes ont été supprimées d'emblée :

- End_Lat, End_Lng : redondantes avec Start_Lat / Start_Lng et rarement renseignées,
- Weather_Timestamp : timestamp souvent manquant, et peu pertinent comparé à Start_Time.

Les noms de colonnes contenant des parenthèses ont été renommés pour faciliter leur manipulation, par exemple : Temperature(F) → Temperature, Humidity(%) → Humidity, etc.

5.2 Gestion des valeurs manquantes

Un traitement spécifique a été appliqué selon la nature des variables :

- Pour les variables numériques continues (Temperature, Humidity, Visibility, etc.), les valeurs manquantes ont été remplacées par la **moyenne** globale de chaque colonne.
- Pour les variables catégorielles importantes (Wind_Direction, Weather_Condition), les valeurs manquantes ont été imputées par la **classe majoritaire** (respectivement CALM et Fair).

5.3 Estimation automatique des phases de la journée

Certaines colonnes du dataset décrivent la période de la journée au moment de l'accident (Sunrise_Sunset, Civil_Twilight, etc.). Lorsqu'elles étaient manquantes, elles ont été complétées à l'aide de la bibliothèque Astral : la position solaire (élévation) a été recalculée à partir des coordonnées GPS et de l'horaire de l'accident. Selon l'élévation, la période (jour/nuit) a été déterminée en fonction de l'angle solaire correspondant (0°, 6°, 12°, 18°).

5.4 Transformation des données catégorielles

Les colonnes booléennes ont été converties en entiers. Un sous-ensemble de données a été extrait pour ne conserver que les enregistrements localisés à Las Vegas (état du Nevada). Les coordonnées Start_Lat et Start_Lng ont été standardisées avec StandardScaler avant d'être utilisées pour le clustering.

5.5 Création de jeux de données spécialisés

Trois sous-ensembles ont été créés pour répondre aux différentes problématiques d'analyse :

- **Clustering** : sélection des variables géographiques et d'infrastructure pertinentes pour regrouper les accidents selon leur localisation et leur environnement immédiat.
- **Supervised learning** : dataset allégé pour les tâches de classification et de régression. Certaines variables peu informatives (Country, toujours à US, ou Turning_Loop, systématiquement false) ont été supprimées.
- **Anomalies** : sous-ensemble conservant la granularité temporelle (Start_Time) afin de permettre une agrégation par jour ou par période.

Pour ce qui est du dataset "Supervised learning", avant l'entraînement qui sera fait dessus dans le futur, un prétraitement a été appliqué sur les données :

- Les colonnes booléennes ont été castées en entiers.
- Les colonnes catégorielles de type string ont été transformées via StringIndexer puis encodées en one-hot avec OneHotEncoder.
- Toutes les variables explicatives (à l'exception de la colonne Duration, notre variable cible) ont été rassemblées dans un vecteur de caractéristiques à l'aide du VectorAssembler.

Chaque sous-ensemble est exporté en tant que fichier CSV unique (via `coalesce(1)`) avec un en-tête clair, facilitant leur réutilisation dans les étapes ultérieures. Les fichiers générés sont sauvegardés dans un dossier /data local au projet.

Cette étape de prétraitement constitue une fondation essentielle pour l'ensemble du projet. Elle garantit l'intégrité statistique des données, limite les biais d'apprentissage, et assure une séparation claire des cas d'usage, tout en exploitant efficacement les capacités de traitement distribuées de Spark.

6 Méthodes de résolutions et résultats

6.1 Classification de la sévérité

Pour résoudre cette tâche de classification nous avons utilisés 2 modèles:

- RandomForest: les random forest ont généralement de très bons résultats sur les tâches de classification. Pour des résultats reproductibles nous avons utilisé la seed 42.
- LogisticRegression: la régression logistique est une bonne méthode de classification qui est généralement utilisé comme baseline pour des tâches de classification multi classe.

Comme pour la partie traitement de données nous avons utilisés Spark pour nos entraînements de modèles au travers de la librairie SparkML, cela permet une meilleure gestion de la mémoire dans le cas de gros jeu de données comme le nôtre.

Pour réaliser l'entraînement de ces modèles nous avons séparés les données en deux ensemble, un ensemble d'entraînement représentant 80% du jeu de données et un ensemble de test qui est composé des 20% restants. Pour obtenir des résultats reproductibles nous avons utilisé 42 comme seed lors du split.

Une fois les données séparées entre entraînement et test on a réaliser un grid search à l'aide de TrainValidationSplit pour ces deux modèles. Pour choisir le meilleur modèle pendant le grid search nous avons utilisé le **F1-score pondéré**.

Pour le RandomForest nous avons utilisé la grille de paramètres suivante:

Hyperparamètre	Valeurs testées
maxDepth	5, 10
numTrees	10, 20, 30
minInstancesPerNode	1, 3, 5

Table 2: Grille d'hyperparamètres testés pour le Random Forest

Le modèle ayant donné les meilleurs résultats lors du grid search pour le RandomForest est le modèle avec une profondeur maximal de 10, 10 arbres et le nombre minimale d'instance avant split d'un noeud de 1.

Pour la régression logistique nous avons utilisé la grille de paramètres suivante:

Hyperparamètre	Valeurs testées
regParam	0.01, 0.1
elasticNetParam	0.0, 0.5, 1.0
maxIter	20, 50, 100

Table 3: Grille d'hyperparamètres testés pour la régression logistique

Le modèle ayant donné les meilleurs résultats lors du grid search pour la régression logistique est le modèle avec un paramètre de régulation de 0.01, un paramètre de régulation elasticNet de 0.0 ce qui signifie une régulation purement L2 et un nombre d'itération maximal de 20.

Comparaison des performances

Nous avons évalué les deux modèles sur l'ensemble de tests en utilisant des versions pondérés de la précision, du recall et du F1-score. Les résultats sont les suivants:

Modèle	Précision	Recall	F1-score
RandomForest	0.80	0.80	0.71
Régression Logistique	0.82	0.84	0.82

Table 4: Performances comparées des modèles de classification

La régression linéaire apparaît ici comme le meilleur modèle. Pour mieux étudier les différences entre les prédictions de ces 2 modèles nous avons réalisé leur matrice de confusion.




Figure 9: Matrice de confusion Random-Forest




Figure 10: Matrice de confusion Logistic-Regression

On se rend finalement compte que le RandomForest prédit presque uniquement des sévérité 2 mais comme c'est la sévérité la plus répandue cela nous donne de bons résultats au global. Alors que pour la régression logistique celle-ci prédit mieux les autres classes et ainsi même si elle fait plus d'erreurs pour la classe 2 comme les autres classes sont tout de même bien prédites, elle obtient bien de meilleurs résultats globaux. Ce qui peut expliquer la mauvaise performance du RandomForest peut être des hyperparamètres trop petits mais nous avons choisi ceux-ci pour des raisons de performance au vu de la taille du dataset et de la capacité de traitement de nos ordinateurs. Ainsi pour cette tâche de classification sur la sévérité des accidents de la route aux US le meilleur modèle est la **régression logistique**.

6.2 Régression sur la durée impactée sur le trafic de l'accident

Pour prédire la durée d'impact sur le trafic des accidents, nous avons formulé cette tâche comme un problème de régression. Deux modèles de régression ont été implémentés à l'aide de SparkML : un **RandomForestRegressor** et une **régression linéaire**.

Les données ont ensuite été séparées en deux ensembles :

- 80% pour l'entraînement
- 20% pour le test

Le split a été réalisé avec une seed de 42 pour garantir la reproductibilité.

Modèle 1 : RandomForestRegressor

Pour le modèle Random Forest, nous avons utilisé la grille d'hyperparamètres suivante :

Hyperparamètre	Valeurs testées
maxDepth	5, 10
numTrees	10, 20
minInstancesPerNode	1, 5

Table 5: Grille d'hyperparamètres pour RandomForestRegressor

Le meilleur modèle obtenu a une profondeur maximale de 10, 10 arbres, et un nombre minimal d'instances par nœud de 1. Ce modèle a été sélectionné à l'aide d'un TrainValidationSplit, avec comme métrique d'évaluation la **RMSE (root mean squared error)**.

Modèle 2 : Régression linéaire

Pour la régression linéaire, nous avons testé la grille d'hyperparamètres suivante :

Hyperparamètre	Valeurs testées
regParam	0.01, 0.1
elasticNetParam	0.0, 0.5, 1.0
maxIter	20, 50, 100

Table 6: Grille d'hyperparamètres pour la régression linéaire

Le meilleur modèle utilise une régularisation L2 (elasticNetParam = 0.0) avec un paramètre de régularisation (regParam) de 0.01 et un nombre d'itérations de 20.

Comparaison des performances

Nous avons évalué les deux modèles sur l'ensemble de test à l'aide des métriques classiques de régression : RMSE, MAE et R^2 . Les résultats sont les suivants :

Modèle	RMSE	MAE	R^2
RandomForest	2.51e+07	2861.50	0.3748
Régression Linéaire	3.14e+07	3661.94	0.2183

Table 7: Performances comparées des modèles de régression

Le modèle **RandomForestRegressor** surpasse la régression linéaire sur toutes les métriques, en particulier sur le R^2 , indiquant une meilleure capacité à expliquer la variance de la variable cible. Cela est cohérent avec la nature possiblement non linéaire des facteurs influençant la durée d'impact des accidents.

Voici un échantillon aléatoire de 10 prédictions comparées aux valeurs réelles :

On constate que les prédictions de la régression linéaire sont globalement plus éloignées de la réalité, notamment pour les valeurs extrêmes. Le Random Forest parvient mieux à modéliser ces cas, ce qui le rend plus adapté pour cette tâche.

6.3 Clustering sur les positions des accidents et leurs champs associés

Pour explorer la distribution spatiale des accidents, nous avons réalisé un clustering géographique à l'aide des coordonnées de latitude et longitude. La ville de **Las Vegas**

Durée réelle (s)	Prédiction RF	Prédiction LR
4524	7657.30	7955.89
3626	4102.27	3316.15
1772	4460.40	2106.32
4536	7021.91	7520.30
5559	4120.76	2979.61
39064	15214.57	9827.61
4810	7429.25	8604.67
3750	7606.97	7967.19
7462	7591.83	8425.07
21600	17426.03	8632.51

Table 8: Échantillon des prédictions sur 10 exemples

a été choisie pour sa morphologie urbaine distincte, caractérisée par des artères principales (comme le Las Vegas Strip) et des quartiers résidentiels bien délimités, ce qui en fait un cas pertinent pour identifier des regroupements spatiaux d'accidents.

Clustering avec KMeans

Nous avons appliqué l'algorithme KMeans avec $n_clusters=5$, sélectionné de manière empirique pour représenter un nombre raisonnable de zones d'accidents. Le résultat est visualisé sur une carte Folium (figure 11), où chaque accident est coloré selon son cluster.




Figure 11: Clusters KMeans des accidents à Las Vegas

Clustering avec DBSCAN

Nous avons également testé l'algorithme DBSCAN avec ($eps= 0.12$, $min_samples= 10$), qui permet de détecter des clusters de densité variable sans spécifier le nombre de groupes a priori. Cette méthode identifie naturellement les zones denses (potentiellement à risque) et isole les points bruités. La figure 12 montre la répartition des clusters DBSCAN sur la même zone géographique.




Figure 12: Clusters DBSCAN des accidents à Las Vegas

Interprétation

Les deux approches révèlent des regroupements d'accidents autour des axes principaux et dans certaines zones résidentielles, confirmant l'hypothèse d'une structuration spatiale influencée par la configuration de la ville. KMeans fournit une segmentation cohérente mais impose une partition fixe, tandis que DBSCAN permet d'isoler les zones à forte densité de manière plus flexible.

6.4 Détection d'anomalies parmi les séries d'accidents

L'objectif de cette section est d'identifier des journées présentant un nombre anormalement élevé d'accidents, potentiellement liées à des événements exogènes exceptionnels (conditions météorologiques extrêmes, pics de trafic, catastrophes locales, etc.).

Préparation et agrégation des données. Les données d'accidents ont été filtrées pour ne conserver que celles survenues en **2019**. Une étape d'agrégation a été réalisée pour calculer, pour chaque couple (date, État), le nombre total d'accidents survenus ce jour-là. Cette agrégation permet de transformer les données individuelles en une série temporelle de comptages, adaptée à l'analyse statistique de la fréquence d'occurrence.

Normalisation des valeurs. Les valeurs de comptage ont ensuite été **standardisées** via un centrage-réduction (z-score), afin d'éliminer les effets d'échelle et rendre les observations comparables entre elles. Cette étape est essentielle pour les méthodes sensibles aux distances ou aux densités locales.

Méthode par Local Outlier Factor (LOF). Le premier algorithme utilisé est le **Local Outlier Factor (LOF)**, fondé sur la notion de densité locale. Chaque point (jour/État) est comparé à ses voisins proches, et un score d'isolement est calculé. Les points dont la densité est significativement plus faible que celle de leur voisinage sont considérés comme des anomalies.

Dans notre implémentation, nous avons fixé le nombre de voisins à `n_neighbors = 20`, ce qui permet d'évaluer la densité locale sur une zone restreinte autour de chaque point. Le taux de contamination, c'est-à-dire la proportion attendue d'anomalies dans l'ensemble des données, a été ajusté dynamiquement en fonction de la taille de l'échantillon, avec une borne maximale correspondant à 20 jours considérés comme potentiellement atypiques.

Cette méthode a permis d'identifier plusieurs journées anormales, réparties dans différents États, caractérisées par un nombre d'accidents anormalement élevé par rapport au comportement général observé sur l'année. Ces anomalies peuvent refléter des événements locaux, tels que des perturbations météorologiques ou des incidents exceptionnels.

Méthode par *Isolation Forest*. En complément, une seconde approche a été utilisée : l'algorithme **Isolation Forest**, qui repose sur le principe que les anomalies sont plus faciles à isoler dans une structure en arbre que les points réguliers. Le modèle construit une forêt d'arbres de partition aléatoires et évalue la profondeur moyenne nécessaire pour isoler chaque point.

L'algorithme a été paramétré avec un taux de contamination fixé dynamiquement, correspondant à 5 jours attendus comme anomalies. Une graine aléatoire fixe (`random_state = 42`) a été utilisée pour assurer la reproductibilité des résultats.

Cette méthode s'est révélée efficace pour détecter des cas extrêmes. Parmi les journées identifiées comme anomalies par *Isolation Forest*, on retrouve notamment le **23 décembre 2019 en Californie**, connu pour un enchaînement de suraccidents liés à un épisode de gel intense.

Comparaison des méthodes. Les deux approches ont permis d'identifier des ensembles partiellement disjoints de jours anormaux : LOF a tendance à détecter des anomalies *locales* (relativement à la densité de leur voisinage immédiat), tandis qu'*Isolation Forest* détecte des anomalies plus *globales*, c'est-à-dire fortement isolées dans l'espace des variables. Leur complémentarité permet une détection robuste et multi-échelle des événements rares dans les données.

7 Discussion des résultats et limites

Les résultats obtenus au fil de ce projet offrent une vision enrichie sur la compréhension des accidents de la route aux États-Unis, tant sur le plan exploratoire que prédictif.

L'analyse exploratoire a révélé une très forte concentration d'accidents de sévérité 2, représentant **80%** des cas (plus de 6 millions d'enregistrements). Cette surreprésentation implique un déséquilibre de classes important dans la suite du traitement par modèles supervisés. L'analyse temporelle a mis en évidence des pics accidentogènes en **décembre (700 000 cas)** et lors des heures de pointe (**6h–8h** et **15h–18h**), soulignant l'influence cruciale des conditions de circulation.

Concernant la classification de la sévérité, les deux modèles testés ont donné des performances contrastées. Le **RandomForestClassifier** atteint un F1-score de **0,71**, mais souffre d'un biais fort vers la classe dominante (sévérité 2). À l'inverse, la **régression logistique** atteint un F1-score de **0,82** avec une meilleure couverture des classes 3 et 4, ce qui la rend plus adaptée à un contexte opérationnel nécessitant une identification fine des accidents graves.

Pour la régression sur la durée d'impact, le **RandomForestRegressor** affiche un RMSE de $2,51 \times 10^7$, un MAE de **2,861,50 s** et un R^2 de **0,375**, ce qui montre une performance acceptable, mais loin d'être parfaite. La régression linéaire, avec un R^2 de **0,218**, est significativement moins performante. Ces résultats suggèrent que la durée d'impact est influencée par des relations non linéaires entre variables (conditions météo, horaires, infrastructures, etc.), difficiles à modéliser sans algorithme robuste.

Le **clustering géographique** mené sur Las Vegas a permis d'identifier 5 zones accidentogènes cohérentes avec la structure urbaine : axes majeurs, zones résidentielles denses, etc. L'approche DBSCAN a mis en évidence des zones à forte densité, indépendamment d'un nombre de clusters prédéfini. Cela permettrait, en pratique, de prioriser certaines zones pour des actions de prévention ciblées.

Enfin, la **détection d'anomalies** a identifié des jours avec un volume d'accidents exceptionnel, comme le **23 décembre 2019 en Californie**. LOF et Isolation Forest ont permis une détection complémentaire (anomalies locales vs globales), utile pour anticiper ou expliquer des pics inhabituels liés à des événements extérieurs.

Limites identifiées

- **Déséquilibre des classes** : Les classes minoritaires (1 et 4) sont sous-représentées, ce qui affecte la sensibilité des modèles.
- **Capacité de calcul** : Les contraintes matérielles ont limité l'exploration des hyperparamètres (notamment pour Random Forest).
- **Qualité et complétude des données** : Présence de valeurs manquantes, notamment dans les données météorologiques.
- **Généralisation restreinte** : Certaines analyses (clustering) ont été localisées à une seule ville ; l'extension nationale reste à faire.

8 Conclusion

Ce projet démontre l'intérêt concret de l'exploitation des données massives d'accidents routiers à travers une approche mêlant data science, machine learning et visualisation. Chaque tâche menée s'inscrit dans une logique de résolution d'un besoin métier réel.

- **Classification de la sévérité** : Grâce à un modèle atteignant un F1-score de **0,82**, il devient possible d'intégrer une prédiction de gravité dans les systèmes d'alerte des secours, afin de prioriser les interventions selon les cas les plus critiques.
- **Régression de la durée d'impact** : La prédiction du temps de blocage permettrait d'alimenter les centres de gestion du trafic pour adapter en temps réel les déviations ou les affichages dynamiques, anticipant ainsi les congestions.
- **Clustering géographique** : L'identification de zones à risque offre un outil de support à la décision pour les collectivités locales (ex. : urbanisme, signalisation), les compagnies d'assurance (ex. : tarification au risque) ou encore les plateformes de navigation (Waze, Google Maps).
- **Détection d'anomalies** : Les pics d'accidents isolés peuvent alerter les autorités sur des situations exceptionnelles (météo, événements publics, manifestations), favorisant la mise en place rapide de mesures de sécurité.

Au-delà de la valeur analytique, ce travail prouve la faisabilité de créer un système d'analyse décisionnelle automatisé à partir de données publiques massives. Les résultats peuvent directement être appliqués à des cas concrets dans le secteur public (sécurité routière, transports), comme dans le secteur privé (assurance, logistique, smart cities).

Les prochaines étapes pourraient inclure :

- le déploiement de modèles plus avancés (ex. : deep learning, séries temporelles),
- l'intégration de flux temps réel pour du prédictif dynamique,
- l'analyse croisée avec des données extérieures comme le trafic habituel ou les capteurs des voitures accidentées.

Ainsi, ce projet ouvre la voie vers des outils intelligents d'aide à la décision pour rendre la route plus sûre, plus fluide, et plus intelligente.

References

- [1] Kaggle. *US Accidents Data Analysis (2016-2023)*. <https://www.kaggle.com/datasets/sobhanmoosavi/us-accidents>.